INSTITUTO FEDERAL
Piauí
Campus Pedro II

Inteligência Artificial

(*Data Science* e *Machine Learning*)

Prof. Dr. Manuel Gonçalves da Silva Neto
manuel@ifpi.edu.br

Agenda:

Introdução ao aprendizado de máquina (*machine learning*)

Ferramentas (recomendadas):

- Edição de código e projetos:

  https://colab.research.google.com *(Google Colab)*

  https://archive.ics.uci.edu/ml/index.php (*Repositório de dados UCI*)

  https://replit.com/ (Replit)

  http://draw.io/ (Diagramas online)

  *Spyder3 (Editor/IDE Python) ou VSCode: Requerem instalação local

  *Anaconda ou equivalente (Pacotes Python para *Data Science* – instalação local)

Objetivos:

- Apresentar conceitos iniciais de Aprendizado de Máquina (AM) ou *Machine Learning*

Motivação

- Escrever um programa de computador que:
  - Reconheça pessoas pelo rosto
    - Problemas:
      - Diferentes expressões faciais
      - Alterações na face (ex. óculos, bigode)
      - Cortes de cabelo
      - Etc.

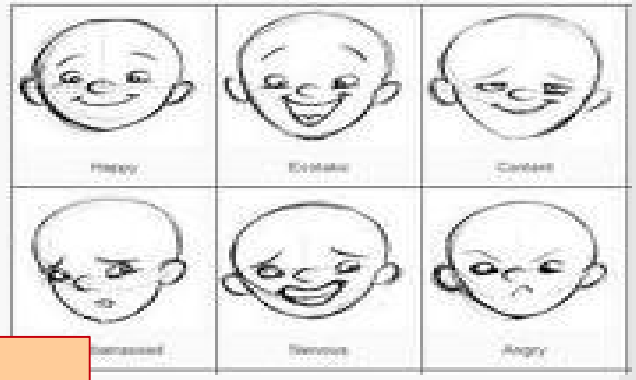

Que características considerar??

Seres humanos: reconhecimento de padrões, aprendizado do que deve ser observado após vários exemplos

Motivação

- Escrever um programa de computador que:
  - Faça diagnóstico de pacientes por sintomas e exames
    - Médico: formação e experiência

  - Responda a questões sobre vendas como:
    - Quais produtos são vendidos em conjunto?
    - Que produto recomendar a um cliente?
    - Como agrupar clientes para melhor marketing?

Inteligência Artificial e AM

- IA era vista como área teórica
  - Aplicações em problemas de pouco valor prático

- 1970: disseminação maior em problemas reais
  - Sistemas Especialistas / baseados em conhecimento
    - Conhecimento de especialista codificado
      - Frequentemente por regras lógicas

Como codificar subjetividade/intuição de especialista?
E como lidar com falta de cooperação?

Inteligência Artificial e AM

- Necessidade de ferramentas mais autônomas
  - Reduzindo necessidade de intervenção humana e dependência de especialistas

Aprendizado de Máquina: técnicas capazes de criar,a partir de experiência passada, uma hipótese (função) capaz de resolver o problema;

- Ex: **Se** temperatura > 37º C **e** tem dores **então** está doente
  - Regra definida a partir de prontuários médicos

Histórico de AM

1950s > 1960s > 1970s > 1980s > 1990s > 2000s

- 1952: programa jogador de damas de Samuel

- 1959: modelo Pandemonium de Selfridge
  - Reconhecimento de padrões
  - Padrão é reconhecido em partes antes do total
  - Aprendizado por meio de ajustes de pesos

Histórico de AM

1950s > 1960s > 1970s > 1980s > 1990s > 2000s

- Redes Neurais: Perceptron (1957), Adaline (1960)
- 1969: Minsky e Papert provam limitações do Perceptron

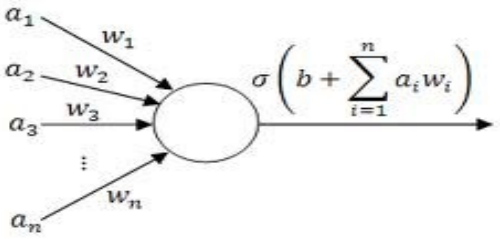

Histórico de AM

1950s > 1960s > 1970s > 1980s > 1990s > 2000s

- Indução simbólica de conceitos
- Sistemas especialistas e o gargalo de aquisição de conhecimento
- Algoritmo ID3 (*Iterative Dichotomiser 3*) de Quinlan

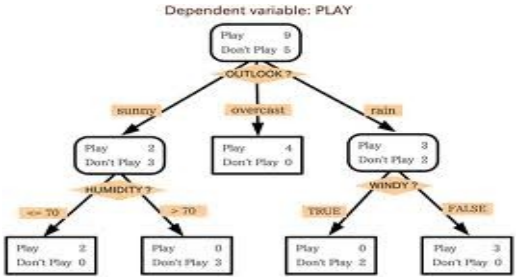

Histórico de AM

1950s > 1960s > 1970s > 1980s > 1990s > 2000s

- Aprendizado de Regras
- EBL (*Explanation-based Learning*)
- Ressurgimento das Redes Neurais (*backpropagation* - 1986)
- Teoria de Aprendizado PAC (*Probably Approximately Correct*)
  - Estrutura para análise matemática de AM
- Foco em metodologia de experimentos

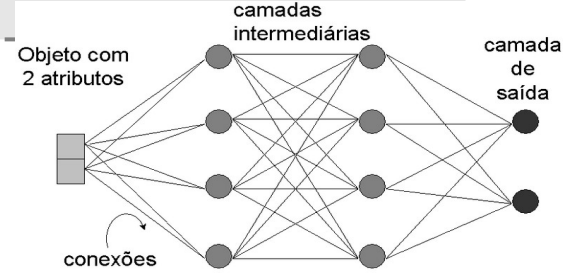

Histórico de AM

1950s > 1960s > 1970s > 1980s > 1990s > 2000s

- Sistemas Inteligentes Híbridos
- Mineração de Dados (1996) e de Textos
- Agentes de software adaptativos e aplicações na web
- Aprendizado por Reforço
- ILP (*Inductive Logic Programming*)
- *Ensembles*: *Bagging*, *Boosting* e *Stacking*
- Aprendizado por redes bayesianas

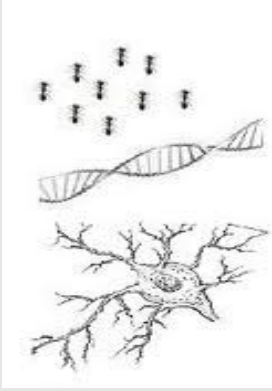

- Computação Bioinspirada

Histórico de AM

1950s > 1960s > 1970s > 1980s > 1990s > 2000s

- Máquinas de Vetores de Suporte (*Support Vector Machines*)
- Modelos Gráficos
- Aplicações em:
  - Sistemas de Computadores
    - Engenharia de Software
    - Segurança (detecção de intrusão, virus e worm)
  - Mineração da Web
  - Gerenciamento de E-mail
  - Bioinformática
  - Fluxo contínuo de dados

O que é aprendizado?

- Essencial para comportamento *inteligente*

- Algumas atividades:
  - Memorizar algo
  - Observar e explorar situações para aprender fatos
  - Melhorar habilidades motoras/cognitivas por prática
  - Organizar conhecimento novo em representações apropriadas

Aprendizado de Máquina: definição

Um programa aprende a partir da experiência **E**, em relação a uma classe de tarefas **T**, com medida de desempenho **P**, se seu desempenho em **T**, medido por **P**, melhora com **E**

(Mitchell, 1997)

Algoritmos de AM: induzem uma **função** ou hipótese capaz de resolver o problema **a partir de instâncias do problema a ser resolvido**

Exemplo 1

- **Problema**: aprender a jogar damas
  - **Tarefa T**: jogar damas
  - **Medida de desempenho P**: ?
  - **Experiência E**: ?

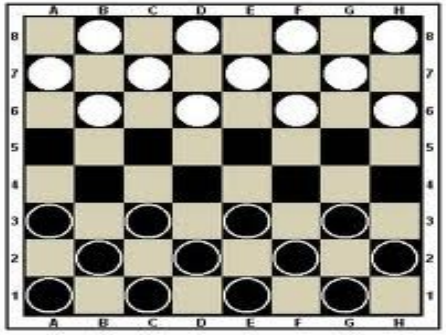

Exemplo 1

- **Problema**: aprender a jogar damas
  - **Tarefa T**: jogar damas
  - **Medida de desempenho P**: porcentagem de jogos vencidos contra adversários
  - **Experiência E**: praticar jogando

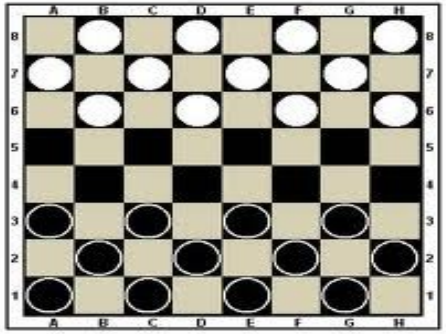

Exemplo 2

- **Problema**: filtrar mensagens de email
  - **Tarefa T**: categorizar mensagens de *email* como *spam* ou legítima
  - **Medida de desempenho P**: ?
  - **Experiência E**: ?

Exemplo 2

- **Problema**: filtrar mensagens de email
  - **Tarefa T**: categorizar mensagens de *email* como *spam/pishing* ou legítima
  - **Medida de desempenho P**: porcentagem de mensagens de *spam/pishing* corretamente identificadas
  - **Experiência E**: conjunto de exemplos de *spams/pishing*

Exemplo 3

- **Problema**: reconhecer escrita manual
  - **Tarefa T**: reconhecer e classificar dígitos manuscritos dentro de imagens
  - **Medida de desempenho P**: ?
  - **Experiência E**: ?

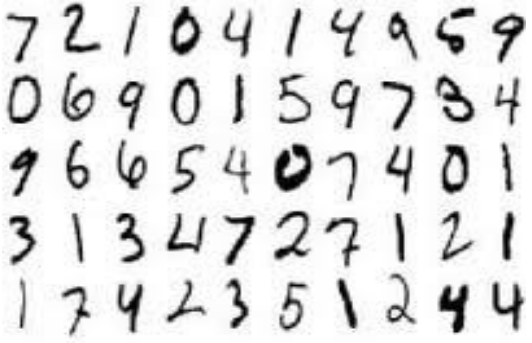

Exemplo 3

- **Problema**: reconhecer escrita manual
  - **Tarefa T**: reconhecer e classificar dígitos manuscritos dentro de imagens
  - **Medida de desempenho P**: porcentagem de dígitos corretamente identificados
  - **Experiência E**: exemplos de dígitos manuscritos com as respectivas classificações

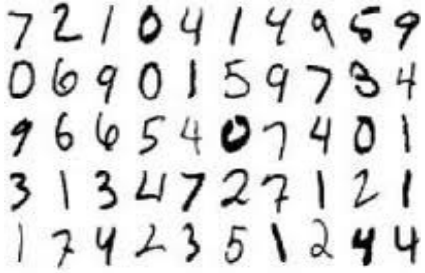

Exemplo 4

- **Problema**: carro autônomo (aprender a dirigir)
  - **Tarefa T**: dirigir em uma rodovia pública usando sensores de visão
  - **Medida de desempenho P**: ?
  - **Experiência E**: ?

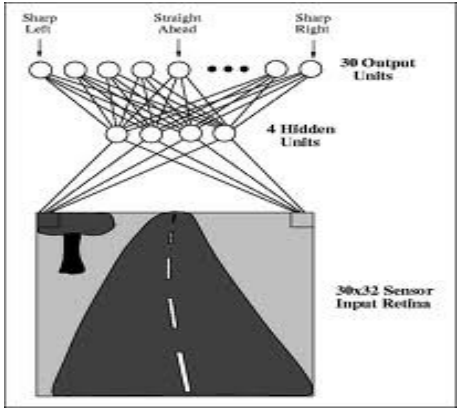

Exemplo 4

- **Problema**: carro autônomo (aprender a dirigir)
  - **Tarefa T**: dirigir em uma rodovia pública usando sensores de visão
  - **Medida de desempenho P**: distância média percorrida antes de um erro
  - **Experiência E**: sequência de imagens e comandos de direção registrados observando um motorista humano

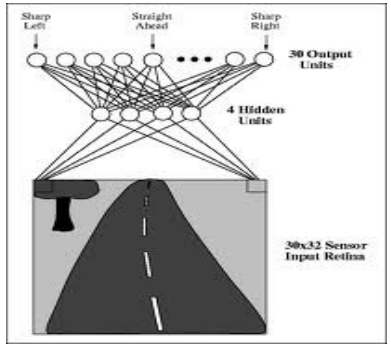

Exemplo 5

- **Problema**: diagnóstico médico
  - **Tarefa T**: diagnosticar o estado de um paciente dado um conjunto de sintomas
  - **Medida de desempenho P**: ?
  - **Experiência E**: ?

Exemplo 5

- **Problema**: diagnóstico médico
  - **Tarefa T**: diagnosticar o estado de um paciente dado um conjunto de sintomas
  - **Medida de desempenho P**: porcentagem de pacientes corretamente diagnosticados
  - **Experiência E**: prontuários médicos de pacientes com seus diagnósticos

Exemplo 6

- **Problema**: detectar bons clientes
  - **Tarefa T**: classificar potenciais clientes como bons ou maus pagadores
  - **Medida de desempenho P**: ?
  - **Experiência E**: ?

Exemplo 6

- **Problema**: detectar bons clientes
  - **Tarefa T**: classificar potenciais clientes como bons ou maus pagadores
  - **Medida de desempenho P**: porcentagem de clientes classificados
  - **Experiência E**: uma base de dados histórica em que os clientes já conhecidos são previamente classificados como bons ou maus pagadores

Inferência Indutiva

- A Inferência Indutiva é um dos principais meios para a aquisição de novos conhecimentos

- **Indução**: raciocínio para obter conclusões sobre todos os membros de uma classe pelo exame de alguns membros da classe

Raciocínio do particular para o geral

Inferência indutiva: exemplo

- Se eu noto que:
  - Todos pacientes com déficit de atenção atendidos em 1986 sofriam de ansiedade
  - Todos pacientes com déficit de atenção atendidos em 1987 sofriam de ansiedade
  - ...
  - ▲ **Posso inferir que pacientes que sofrem de déficit de atenção também sofrem de ansiedade**

Isto pode ser ou não verdade,

mas propicia uma boa generalização

Conjunto de dados

- Experiência pode ser provida por um conjunto de dados (de treinamento) e sua eficácia avaliada em outra parcela destes dados (teste)
  - Ex. base de dados de um hospital. Quais informações são relevantes para o problema?

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Conjunto de dados

- Hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Meta: induzir hipótese para fazer diagnósticos corretos para novos pacientes

Conjunto de dados

- Hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Cada linha (paciente) é um dado
(objeto, exemplo, padrão ou registro)

Conjunto de dados

- Hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Cada objeto é uma tupla com valores de características (atributos, campos ou variáveis), que descrevem seus principais aspectos

Conjunto de dados

- Hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Atributo de saída (alvo/meta): presente em algumas tarefas, seus valores devem ser estimados usando outros atributos (de entrada/preditivos)

Importante: atributos de **identificação** e **nome** não possuem **relação com a doença** e não são utilizados como entradas

Conjunto de dados

- Hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Importante: lidar com dados imperfeitos (ruídos, ausentes, etc.)

AM: multidisciplinar

Probabilidade e Estatística

Teoria da Informação

Aprendizado de Máquina

Teoria da Computação

Neurociência

...

Tarefas de Aprendizado

- Preditivas vs Descritivas

Previsão	Descrição
Encontrar função (modelo ou hipótese) que possa ser utilizada para prever um **rótulo** ou **valor** para novos dados	Explorar ou descrever um conjunto de dados
Objetos na forma (entrada, saída)	Objetos não possuem saída associada

Tipos de aprendizado

Supervisionado

Classificação e regressão

Não-Supervisionado

Clusterização

Importante: divisão não é rígida e existem modelos intermediários, ex: semi-supervisionado;

Aprendizado supervisionado

- Supervisor externo
  - Conhece saída desejada para cada exemplo
    - Representado por conjunto de pares ($\mathbf{x}$, y)
      - Ex.: $\mathbf{x}$ = sintomas e y = diagnóstico

Classificação	**Regressão**
Rótulos discretos (classes)	Rótulos contínuos (valores)
Ex.: diagnóstico, bom/mau pagador, etc.	Ex.: peso, altura, salário, etc.

Aprendizado não supervisionado

- Algoritmos não fazem uso de atributo de saída
  - Exploram regularidades e distribuição dos dados

Sumarização	Associação
Encontrar descrição compacta para dados	Encontrar padrões frequentes de associações entre atributos

Agrupamento (*clusters*)

Dados agrupados de acordo com sua similaridade

Hierarquia de aprendizado

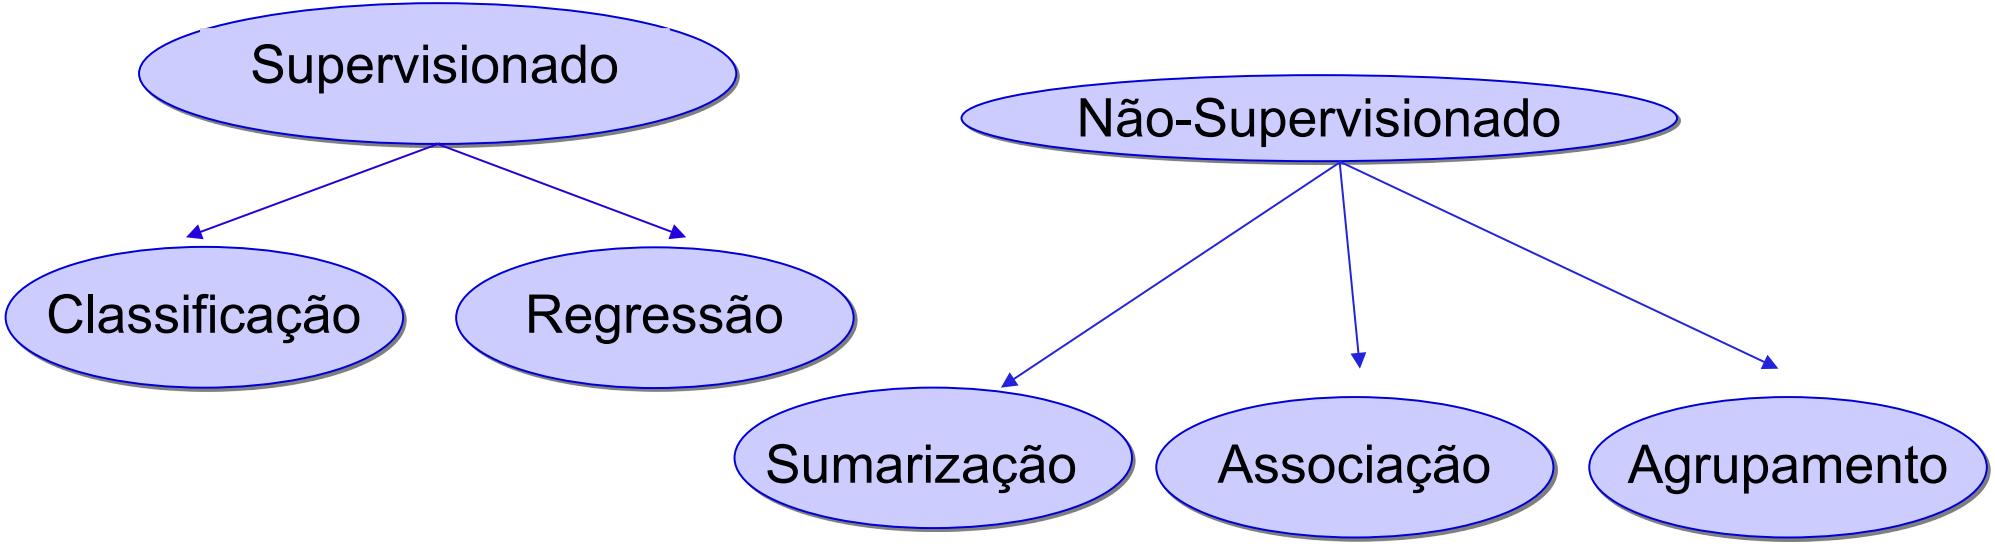

Aprendizado por reforço

- Reforçar/recompensar ações positivas e punir ações negativas
  - Crítico externo

Aprendizado supervisionado	Aprendizado por reforço
• Supervisor • É dito o que fazer • Mais rápido	• Crítico • Faz e vê o que acontece • Mais lento

Aprendizado semi-supervisionado

- Poucos exemplos de dados rotulados e um grande número de dados não rotulados
  - Faz uso efetivo de dados não rotulados pode exigir o uso ou inspiração de métodos não supervisionados, como agrupamento e estimativa de densidade

Aprendizado supervisionado	Aprendizado semi-supervisionado
• Supervisor • É dito o que fazer • Mais rápido	• Supervisiona, agrupa e estima • Os rótulos podem não ser as verdades que esperamos • Grau de incerteza

Generalização

- Capacidade de generalização de uma hipótese:
  - Propriedade de continuar válida para outros objetos que não fazem parte de seu conjunto de treinamento

Problemas:

Overfitting: especialização nos dados de treinamento, não generaliza

Underfitting: baixo acerto mesmo nos dados de treinamento

Viés indutivo

- **Aprendizado**: busca de hipótese em espaço de possíveis hipóteses
  - Que descreva relacionamentos entre os dados
  - E se ajuste aos dados de treinamento

- Todo algoritmo de AM indutivo tem um viés
  - Na escolha de uma hipótese (ou conjunto)

Sem viés, não haveria generalização (modelos seriam especializados para os exemplos individuais)

Viés indutivo

- Viés de **representação ou linguagem**
  - Define o espaço de busca
  - Restringe hipóteses que podem ser geradas

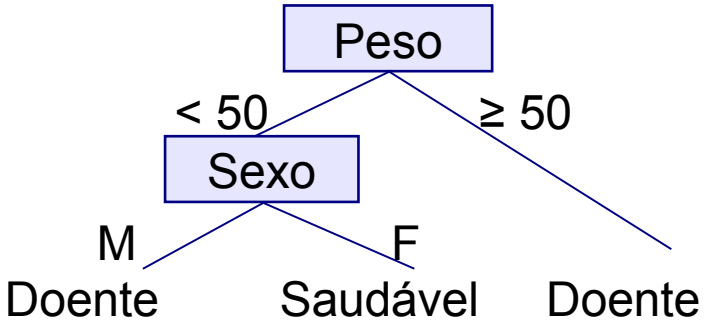

Árvore de decisão

$$\begin{pmatrix} 0.45 & -0.40 & 0.54 & 0.12 & 0.98 & 0.37 \\ -0.45 & 0.11 & 0.91 & 0.34 & -0.20 & 0.83 \\ -0.29 & 0.32 & -0.25 & -0.51 & 0.41 & 0.70 \end{pmatrix}$$

Redes neurais

Se Peso ≥ 50 **então** Doente

Se Peso < 50 **e** Sexo = M **então** Doente

Se Peso < 50 **e** Sexo = F **então** Saudável

Conjunto de regras

AM: outras motivações

- Automatizar o processo de aquisição de conhecimento
- Entender melhor os mecanismos de aprendizado humano
- Algumas tarefas são melhor definidas e/ou executadas a partir de exemplos
  - Ex.: Reconhecer pessoas
- Ser humano não é capaz de explicar (e programar) sua habilidade para executar alguns tipos de tarefas
  - Ex.: Dirigir

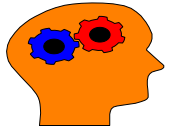

AM: outras motivações

- Quantidade de conhecimento disponível pode ser muito grande para ser descrito (e programado) por humanos
  - Ex.: diagnóstico médico

- Algumas tarefas exigem cálculos complexos, possíveis apenas com computador
  - Ex.: interrelacionar/correlacionar grandes quantidades de dados

- Modelos podem se adaptar a novas situações

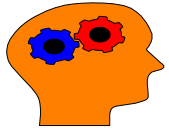

Praticando

1. Pesquise sobre os algoritmos de aprendizado de maquina em Python dos tipos supervisionados (classificação e regressão) e não-supervisionados (clusterização).

Dicas:

- Pacote scikit-learn (sklearn) e TensorFlow no Python.
- Pesquise sobre alternativas ao scikit-learn (matlab, linguagem R, etc..)
- Pesquise sobre alternativas em nuvem para uso de APIs prontas.

What’s next?

- *Time to questions and practice.*